EvoPolicy-SDD: Verificação Orientada por Especificações para a Evolução Segura de Regras de Negócio em Sistemas com Agentes de IA

Lucas Matheus Silva[1]

[1]Instituto Federal da Paraíba (IFPB)
Laboratório de Inovação em Software (LIS)

Abstract. *LLM-based agents increasingly support business decisions, such as approving a refund, by combining rules written in code with policy documents retrieved as justification. When a policy changes, these two artifacts are maintained separately and may stop saying the same thing: the agent keeps running without errors, but its decisions contradict their own justification. We call this coevolution drift. This research proposal presents EvoPolicy-SDD, a specification-driven approach that binds requirements, rules and documents in a versioned specification and blocks decisions when they diverge. In an exploratory mutation study with a prototype (57 automated tests), conventional versioning detects 2 of 12 injected drifts, and the proposed structural checks detect 10 of 12, with one false alarm in 6 benign changes. The two drifts they miss change meaning without changing structure. Adding LLM-based semantic verification between rule and text catches both with either model evaluated (Claude Opus 5.5 and GPT-5.5), reaching 12 of 12; GPT-5.5 adds two false alarms. With either model, an agent that decides from documents alone makes 4 wrong decisions in 18 when the documents are outdated (5 with semantic retrieval), while the specification-driven agent blocks all of them. These results are small-scale and motivate a controlled study with more policies, models and independent labels.*

Resumo. *Agentes baseados em LLMs apoiam cada vez mais decisões de negócio, como aprovar um reembolso, combinando regras escritas em código com documentos de política recuperados como justificativa. Quando a política muda, esses dois artefatos são mantidos separadamente e podem deixar de dizer a mesma coisa: o agente continua funcionando sem erros, mas suas decisões passam a contradizer a própria justificativa. Neste trabalho, esse fenômeno é chamado de deriva de coevolução. Este projeto de pesquisa apresenta o EvoPolicy-SDD, uma abordagem orientada por especificações que amarra requisitos, regras e documentos numa especificação versionada e bloqueia decisões quando eles divergem. Num estudo exploratório de mutações com um protótipo (57 testes automatizados), o versionamento convencional detecta 2 de 12 derivas injetadas, e as verificações estruturais propostas detectam 10 de 12, com um alarme falso em 6 mudanças benignas. As duas derivas que escapam mudam o sentido sem mudar a estrutura. Com uma verificação semântica entre regra e texto feita por LLM, ambas são detectadas pelos dois modelos avaliados (Claude Opus 5.5 e GPT-5.5), e o total chega a 12 de 12; o GPT-5.5 acrescenta dois alarmes falsos. Com qualquer dos dois modelos, um agente que decide apenas a partir dos documentos erra 4 de 18 decisões quando os documentos estão desatualizados (5 com recuperação semântica), enquanto o agente orientado por especificação bloqueia todas. Os resultados são de pequena escala e*

motivam um estudo controlado com mais políticas, modelos e rótulos independentes.

1. Introdução

Empresas têm usado agentes baseados em Modelos de Linguagem de Grande Escala (LLMs) para apoiar decisões operacionais, como aprovar um reembolso, liberar um crédito ou encaminhar um atendimento [Yao et al. 2023, Wang et al. 2024]. Para que essas decisões sigam as políticas da organização, os agentes costumam combinar duas fontes: *regras de negócio escritas em código*, que garantem decisões previsíveis, e *documentos de política em linguagem natural*, recuperados por busca semântica (*Retrieval-Augmented Generation*, RAG) e apresentados como justificativa da decisão [Lewis et al. 2020, Gao et al. 2023]. Esse desenho híbrido também atende a exigências de auditoria e de governança de IA [National Institute of Standards and Technology 2023, União Europeia 2024, Raji et al. 2020].

O problema surge quando a política muda. A regra no código e o texto do documento descrevem a mesma política, mas são mantidos em lugares diferentes, por pessoas diferentes e em momentos diferentes. Se apenas um deles for atualizado, o agente continua funcionando sem nenhum erro, mas passa a tomar decisões que contradizem a própria justificativa. Neste projeto, essa situação é chamada de **deriva de coevolução**: regra executável e documento de evidência deixam de dizer a mesma coisa após uma mudança de política. A Seção 2 ilustra o problema com um exemplo.

Esse tipo de divergência entre artefatos acoplados é conhecido em Engenharia de Software, por exemplo entre código e comentários [Tan et al. 2007, Wen et al. 2019] ou entre código e documentação [Aghajani et al. 2019]. Em agentes de IA, porém, a consequência é mais grave, porque o texto divergente é entregue ao usuário como fundamento da decisão. Trabalhos recentes já transformam políticas em código de guarda para agentes [Zwerdling et al. 2025, Datla et al. 2025], mas tratam uma única versão da política; os próprios autores de [Zwerdling et al. 2025] apontam a gestão do ciclo de vida, quando política ou código mudam, como questão em aberto.

Este projeto propõe o *EvoPolicy-SDD*, uma abordagem orientada por especificações (*Spec-Driven Development*, SDD) em que requisitos, regras e documentos são amarrados numa especificação versionada, e o agente só publica decisões quando esses artefatos estão consistentes entre si. A pesquisa busca responder: *como manter auditáveis as decisões de agentes híbridos quando as políticas de negócio evoluem, e até onde a verificação estrutural e a verificação semântica conseguem detectar a deriva?*

As contribuições pretendidas são: (i) a caracterização da deriva de coevolução em agentes híbridos, com uma taxonomia de tipos de deriva; (ii) um metamodelo e um validador com níveis cumulativos de verificação, que permitem atribuir a detecção a cada mecanismo; (iii) uma verificação semântica entre regra e texto assistida por LLM, voltada às derivas que a verificação estrutural não alcança; e (iv) um estudo empírico, baseado em mutações, sobre ganhos, custos e limites dessas verificações. O protótipo já implementa (ii), uma primeira versão de (iii) com LLMs reais e uma versão inicial do estudo (iv), cujos resultados estão na Seção 6.

O texto está organizado da seguinte forma: a Seção 2 descreve o problema; a Seção 3 apresenta a fundamentação; a Seção 4 discute trabalhos relacionados e a lacuna; a Seção 5 descreve a abordagem; a Seção 6 reporta a avaliação exploratória; a Seção 7 detalha o plano de pesquisa; a Seção 8 discute ameaças à validade; e a Seção 9 conclui.

2. O Problema: Deriva de Coevolução

Exemplo motivador. Considere um agente que apoia atendentes de uma plataforma fictícia de pedidos em decisões de reembolso. Na versão 1 da política, o cliente que desiste do pedido depois do despacho não tem direito a reembolso. A regra em código (`desistência após despacho` → NEGAR) e o documento da política dizem a mesma coisa, e o agente nega o pedido citando o documento correto.

Na versão 2, a empresa cria uma exceção: clientes *premium* podem cancelar até 1 hora após o despacho. A equipe de conteúdo atualiza o documento, mas a regra em código não é alterada. A Figura 1 mostra o que acontece: para um cliente *premium* que cancela 40 minutos após o despacho, o agente aplica a regra antiga e **nega** o reembolso, mas cita como justificativa o documento novo, que diz que o reembolso é **permitido**. Nenhum teste falha, nenhum erro é registrado, e a decisão chega ao atendente com uma justificativa que a contradiz.

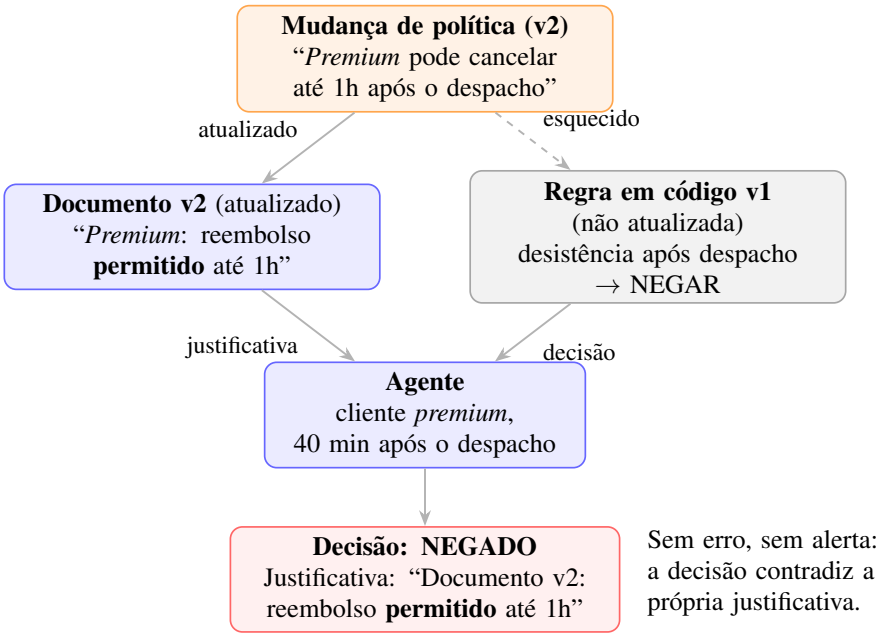


Figura 1. Exemplo de deriva de coevolução: a política muda, o documento é atualizado e a regra em código não.

Tipos de deriva. O exemplo é um de vários casos possíveis. A Tabela 1 resume os tipos considerados neste projeto, que orientam o estudo de mutações da Seção 6.

Por que o versionamento convencional não basta. Numerar versões de documentos e de código, como fazem as equipes em geral, detecta apenas o caso em que as versões declaradas diferem. Nos demais, as versões podem coincidir enquanto o conteúdo diverge. Testes de regressão que verificam apenas a decisão final também não ajudam, porque não olham a justificativa. O problema exige verificar o *vínculo* entre requisito, regra e texto a cada mudança, e não cada artefato isoladamente.

3. Fundamentação

Agentes baseados em LLM e RAG. RAG combina um recuperador e um gerador para que a resposta seja condicionada a documentos externos [Lewis et al. 2020,

Tabela 1. Tipos de deriva de coevolução considerados.

Tipo	O que acontece	Efeito na decisão
Regra sem documento	a regra muda (limiar, precedência, decisão) e o texto não	decisão nova com justificativa antiga
Documento sem regra	o texto muda e a regra não (caso da Figura 1)	decisão antiga com justificativa nova
Atualização parcial	parte dos documentos fica na versão anterior	justificativas de versões misturadas
Requisito órfão	um requisito é criado ou removido sem regra correspondente	comportamento sem respaldo no requisito
Deriva semântica	o sentido muda e as marcas de controle são atualizadas sem revisão real	passa por qualquer checagem estrutural

Gao et al. 2023]. Sistemas RAG apresentam pontos de falha recorrentes de engenharia, como conteúdo ausente e recuperação de trechos inadequados [Barnett et al. 2024], e LLMs podem produzir justificativas plausíveis sem sustentação nas fontes [Ji et al. 2023, Liu et al. 2024].

Especificações como fonte de verdade. Projeto por contrato [Meyer 1992] e engenharia dirigida por modelos [Schmidt 2006] defendem especificações explícitas e verificáveis como fonte do comportamento do software. O SDD retomou esse princípio para guiar agentes de codificação a partir de especificações versionadas [GitHub 2025]. Aqui, o princípio é aplicado a outro alvo: a especificação governa a consistência entre regra executável e texto usado como evidência.

Rastreabilidade e evolução. A rastreabilidade de requisitos liga cada requisito aos artefatos que o implementam [Gotel and Finkelstein 1994, Ramesh and Jarke 2001], e mantê-la sempre atualizada continua sendo um desafio em aberto [Cleland-Huang et al. 2014]. Artefatos acoplados tendem a divergir quando evoluem em ritmos diferentes [Lehman 1980, Zaidman et al. 2011].

Teste de mutação. O teste de mutação avalia a capacidade de detecção de um conjunto de verificações injetando defeitos artificiais [DeMillo et al. 1978, Jia and Harman 2011, Papadakis et al. 2019]; a definição do que conta como defeito exige um oráculo [Barr et al. 2015]. Este projeto adapta a ideia: os operadores de mutação injetam derivas no par especificação–documentos e medem se o validador as detecta.

4. Trabalhos Relacionados

Políticas transformadas em guardas para agentes. [Zwerdling et al. 2025] compilam documentos de política em código de guarda que verifica cada chamada de ferramenta de um agente antes da execução, com testes derivados de trechos do texto da política. [Datla et al. 2025] usam LLMs para traduzir políticas em regras executáveis numa linguagem específica de domínio e comparam o resultado com regras escritas por especialistas. Ambos verificam a correspondência entre texto e regra no momento da construção, para uma única versão da política. *Frameworks* como o NeMo Guardrails [Rebedea et al. 2023] e motores de política como o Open Policy Agent [Open Policy Agent sd] tornam as regras declarativas e versionáveis, mas não as relacionam ao texto apresentado como justificativa.

Políticas e conhecimento que mudam. O PolicyBank [Choi et al. 2026] permite que o agente refine a sua *interpretação* de uma política ambígua a partir de *feedback*, mas a política em si não muda. O *benchmark* HoH [Ouyang et al. 2025] mostra que informação desatualizada na base de recuperação reduz a acurácia de sistemas RAG, mas considera apenas documentos, sem regras executáveis. Na área de processos de negócio, [Hashmi et al. 2018] e [Rinderle et al. 2004] tratam conformidade e mudanças de *workflows*, sem agentes que usam texto como evidência.

Inconsistência entre código e documentação. DocPrism [Xu et al. 2025] e METAMON [Lee et al. 2025] usam LLMs para detectar divergências entre código e documentação de software. São a base mais próxima para a verificação semântica proposta aqui, mas tratam funções e APIs, não regras de negócio que evoluem com uma política.

Lacuna. A Tabela 2 compara os trabalhos. Nenhum deles trata, ao mesmo tempo, regras executáveis, texto de política usado como evidência e a evolução de ambos ao longo de versões. Essa combinação é o foco do EvoPolicy-SDD. A revisão sistemática prevista na Seção 7 [Kitchenham and Charters 2007] confirmará ou refinará essa lacuna.

Tabela 2. Comparação com trabalhos relacionados (✓: trata; ∼: parcialmente; –: não trata).

Trabalho	Regras executáveis	Texto como evidência	Consistência regra–texto	Evolução de versões
[Zwerdling et al. 2025]	✓	∼	∼	–
[Datla et al. 2025]	✓	–	∼	–
[Choi et al. 2026]	–	✓	–	∼
[Ouyang et al. 2025]	–	✓	–	✓
[Xu et al. 2025, Lee et al. 2025]	–	–	✓	–
EvoPolicy-SDD	✓	✓	✓	✓

5. Abordagem Proposta

Esta seção descreve o metamodelo, o fluxo de verificação e decisão, e as categorias de verificação do EvoPolicy-SDD, tal como implementados no protótipo v0.3.0.

Metamodelo. Cada versão da especificação (`specs/vN/specification.yaml`) declara: o esquema de fatos aceitos (tipos `bool`, `str` e `number`); requisitos com identificador estável e critério de aceitação; regras com prioridade, condição, decisão, justificativa, requisitos atendidos e documento associado; uma decisão padrão; e o *digest* do texto aprovado de cada documento. A base documental (`knowledge/vN/policies.json`) traz versão explícita e, para cada regra vinculada, uma marca de integridade (*fingerprint*) SHA-256 [National Institute of Standards and Technology 2015] calculada sobre os atributos estruturados da regra, incluindo a justificativa.

Fluxo de verificação e decisão. A Figura 2 apresenta o fluxo da abordagem.

O fluxo tem duas fases. Na *Fase A*, executada a cada nova versão da política, o validador (1) confere a especificação e os documentos daquela versão e devolve os problemas encontrados, cada um associado a uma categoria. A guarda (2) só libera a versão se não houver nenhuma divergência; caso contrário, a versão é bloqueada e encaminhada para revisão humana (política *fail-closed*). Na *Fase B*, executada a cada solicitação, o

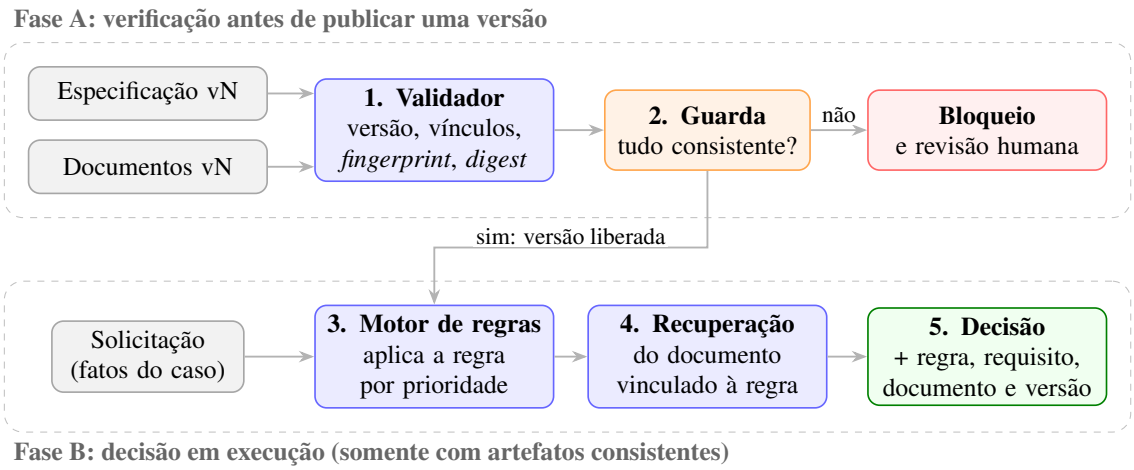


Figura 2. Fluxo de verificação e decisão do EvoPolicy-SDD.

motor (3) aplica as regras em ordem de prioridade sobre os fatos do caso, usando a decisão padrão da especificação quando nenhuma regra se aplica; a recuperação (4) busca o documento vinculado à regra aplicada; e a decisão (5) é registrada com a regra, o requisito, o documento e os *digests* da especificação, da base documental e dos fatos, o que permite reproduzir e auditar cada decisão. As decisões de projeto do protótipo seguem um registro curto de contexto, decisão e consequências, inspirado em registros de decisões de arquitetura [Nygard 2011].

Categorias de verificação e níveis de ablação. Para que a detecção possa ser atribuída a cada mecanismo, e não ao validador como um todo, cada problema pertence a uma categoria, e os níveis L0–L3 ativam subconjuntos cumulativos dessas categorias (Tabela 3). O nível L1 representa o versionamento convencional que qualquer equipe pode adotar; os ganhos atribuíveis à verificação SDD são, portanto, as diferenças entre L1 e L2/L3.

Verificação semântica (L4). As categorias L0–L3 são estruturais e não percebem quando o sentido muda e as marcas são recalculadas. O nível L4 acrescenta a categoria *semântica*: para cada documento, um LLM recebe o texto aprovado, as regras que o citam (condições, decisão, prioridade e justificativa) e os requisitos vinculados, e responde num esquema JSON fixo se eles descrevem a mesma política, listando cada divergência com a regra e o aspecto afetado (limiar, decisão, condição, exceção, precedência ou requisito). A instrução pede que diferenças de redação ou pontuação sejam ignoradas. A instrução inclui todas as regras da especificação com suas condições, para que uma exclusão citada no texto (por exemplo, fraude) seja reconhecida quando outra regra já a decide antes. A verificação também é *fail-closed*: recusa, falha de rede ou resposta fora do esquema geram alerta, nunca aprovação. O protótipo aceita Claude (Anthropic) e GPT (OpenAI) pelos SDKs oficiais e guarda cada resposta num *cache* indexado pelo *hash* do pedido, o que permite repetir o experimento sem novas chamadas.

Papel do LLM na decisão. No agente proposto, o LLM não decide. A regra determinística escolhe a decisão e o documento de evidência; o LLM apenas redige a resposta ao atendente a partir desse documento. A resposta passa por uma conferência automática: se o LLM indicar outra decisão, citar outro documento ou falhar, ela é descartada e usa-se a justificativa da regra.

Tabela 3. Níveis cumulativos do validador.

Nível	Categorias ativas	Interpretação
L0	nenhuma	agente sem guarda
L1	estrutura, versão	versionamento convencional
L2	+ IDs, referências, *fingerprint*	vínculos estruturais regra–documento
L3	+ *digest*, cobertura, esquema	vínculo bidirecional e checagem de tipos
L4	+ semântica (LLM)	regra, texto e requisito dizem o mesmo?

Evolução e análise de impacto. O protótipo oferece ainda operações de diferença entre versões (`diff`), matriz de rastreabilidade requisito–regra–documento (`trace`), recálculo de marcas após revisão humana (`fingerprint`) e o estudo de mutações (`mutate`). Na evolução v1→v2 do domínio de exemplo, a especificação ganha o requisito REQ-05 e a regra REG-PREMIUM-EXC (exceção para cliente *premium* que cancela até 1 hora após o despacho). A análise de impacto identifica exatamente três casos cuja decisão muda (Tabela 4).

Tabela 4. Casos impactados pela evolução v1→v2.

Caso	Decisão v1	Regra v1	Decisão v2	Regra v2
C05	NEGAR	REG-CANCEL-ENVIADO	PERMITIR	REG-PREMIUM-EXC
C06	NEGAR	REG-CANCEL-ENVIADO	PERMITIR	REG-PREMIUM-EXC
C18	NEGAR	REG-CANCEL-ENVIADO	PERMITIR	REG-PREMIUM-EXC

6. Avaliação Exploratória

Os resultados desta seção vêm do protótipo v0.3.0 (57 testes automatizados). A Seção 5.1 e os níveis L0–L3 da Seção 5.2 são determinísticos. O nível L4 e a Seção 5.3 usam dois LLMs reais, o Claude Opus 5.5 (`claude-opus-5-5`) e o GPT-5.5 (`gpt-5.5`), ambos com esforço de raciocínio *medium* e saída em esquema JSON estrito, numa única execução em 12/11/2026; as respostas estão guardadas em *cache* no repositório. A recuperação semântica usa embeddings `text-embedding-3-small`. Os resultados não sustentam inferência estatística: os casos são sintéticos, os rótulos e os mutantes foram escritos pelo próprio autor, há um mutante por família e cada modelo foi executado uma vez.

6.1. Demonstração com Cinco Condições

Dezoito casos sintéticos de reembolso e cancelamento, rotulados para v1 e v2, foram executados em cinco condições (Figura 3). As condições têm capacidades intencionalmente distintas para demonstrar o mecanismo e não constituem um ensaio causal. A condição B3 (regras v2 com documentos v1) acerta todas as decisões, mas 16 das 18 citam evidência com versão ou *fingerprint* incompatível; as duas restantes não citam documento por usarem a decisão padrão. A mesma configuração sob a guarda SDD (P2) é bloqueada integralmente: troca evidência inválida por indisponibilidade. Com os artefatos sincronizados, a guarda não altera o resultado (B2 e P1 empatam).

6.2. Estudo de Mutações

Partindo do par sincronizado (especificação v2 e documentos v2), doze operadores produzem derivas reais (M01–M12) e seis produzem mudanças benignas (N01–N06), com

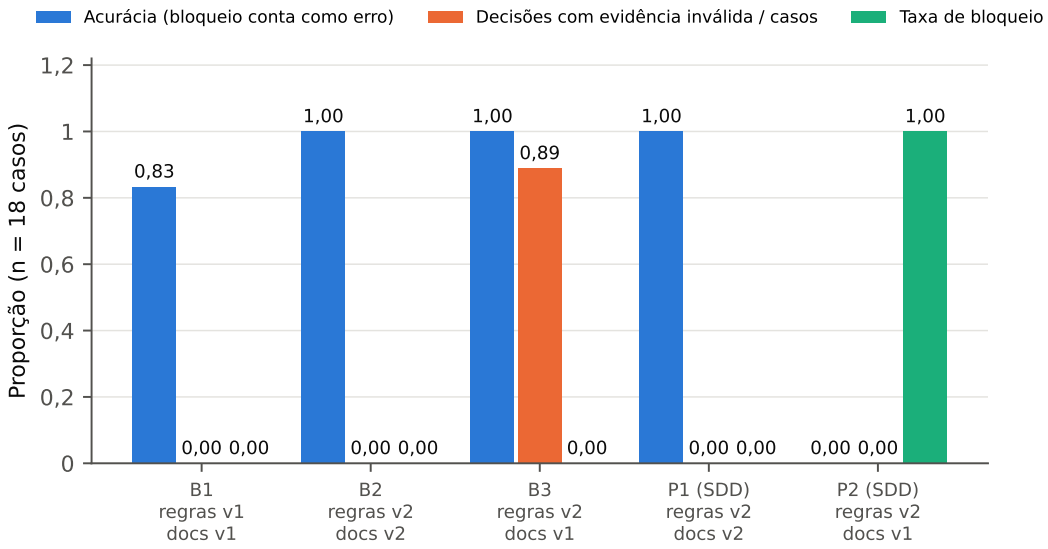


Figura 3. Acurácia, evidência inválida e bloqueio nas cinco condições da demonstração.

rótulo de verdade atribuído *a priori* (Tabela 5). Cada mutante é validado nos cinco níveis e os 18 casos são executados com guarda. A Figura 4 mostra o resultado mutante a mutante.

Tabela 5. Operadores de mutação do estudo exploratório.

ID	Deriva injetada	ID	Mudança benigna
M01	limiar alterado só na especificação	N01	reordenação de regras
M02	precedência trocada	N02	reordenação de requisitos
M03	decisão invertida	N03	reordenação de documentos
M04	regra removida	N04	metadados editoriais
M05	requisito removido	N05	correção de pontuação no texto
M06	requisito sem regra	N06	evolução completa e sincronizada
M07	justificativa contraditória		
M08	atualização parcial (um documento antigo)		
M09	texto editado sem revisão		
M10	texto invertido com marcas recalculadas		
M11	limiar alterado com marcas recalculadas		
M12	base documental v1 inteira		

A Figura 5 agrega os resultados. O versionamento convencional (L1) detecta apenas as duas derivas que mudam a versão declarada (M08 e M12). As marcas de integridade (L2) elevam a sensibilidade para 8/12, sem alarmes falsos. O nível completo (L3) chega a 10/12 ao capturar o requisito sem regra (M06) e a edição de texto sem revisão (M09), mas o *digest* de texto também bloqueia uma correção de pontuação (N05), o único alarme falso observado (precisão de 10/11). O nível L4 detecta as 12 derivas com os dois modelos. Com o Claude, não há alarme falso novo: o único continua sendo N05, causado pelo *digest* herdado de L3. Com o GPT, há dois alarmes falsos a mais (N01 e N06), discutidos adiante.

A Figura 6 traduz a detecção em efeitos operacionais somados sobre os 18 mutantes. As decisões erradas emitidas caem de 9 (L0 e L1) para 1 (L2 e L3), e as decisões emitidas com evidência divergente caem de 101 para 18. O custo aparece no terceiro painel: em L3, a mudança benigna N05 bloqueia 18 decisões. Em L4, nenhuma decisão errada é emitida com nenhum dos modelos; os bloqueios em mudanças benignas são 18

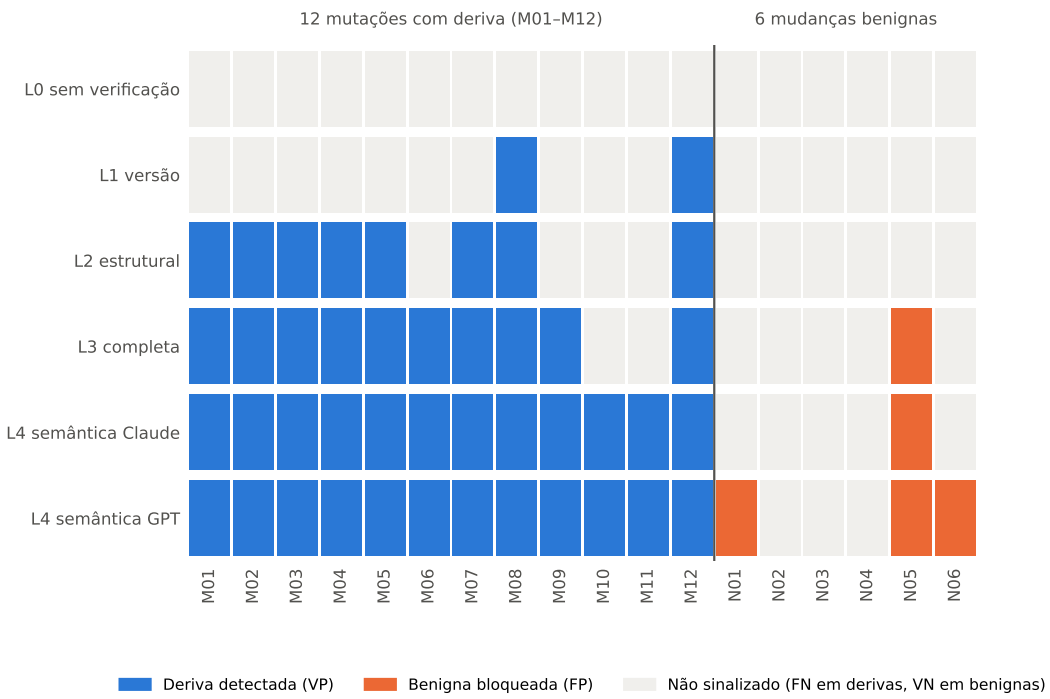


Figura 4. Detecção por mutante e por nível do validador.

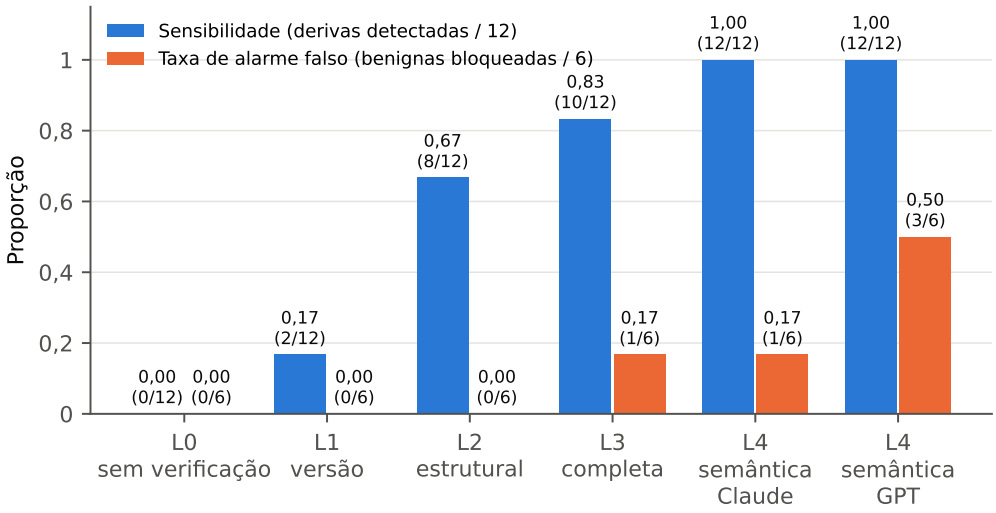


Figura 5. Sensibilidade e taxa de alarme falso por nível do validador.

com o Claude e 54 com o GPT.

Limite estrutural e verificação semântica. M10 e M11 não são detectados por L0–L3. Em ambos, o significado é alterado (o texto da política é invertido, ou o limiar muda mantendo o texto antigo) e as marcas de integridade são recalculadas sem revisão do conteúdo. A verificação estrutural é contornada por construção: *fingerprints* e *digests* atestam que os artefatos não mudaram desde a última aprovação, e não que texto e regra dizem a mesma coisa. Os dois modelos detectam os dois casos. Em M10, aponta que o documento passou a dizer que todo cancelamento após o despacho é negado, enquanto a

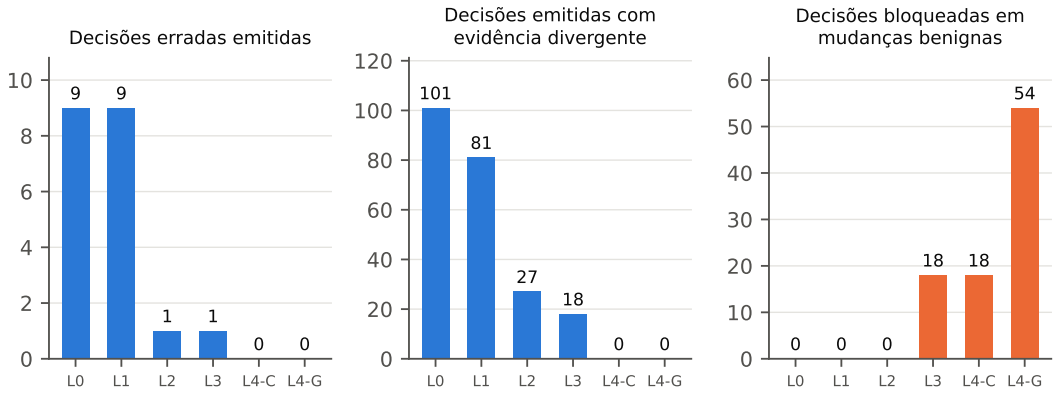


Figura 6. Efeitos operacionais por nível, somados sobre os 18 mutantes (L4-C: Claude; L4-G: GPT).

regra REG-PREMIUM-EXC e o REQ-05 preveem a exceção *premium*. Em M11, aponta que a regra usa 2 horas enquanto o texto e o critério de aceitação dizem 1 hora.

Isolada, a categoria semântica sinaliza, com os dois modelos, as mesmas 8 das 12 derivas (M01–M04 e M09–M12). As quatro que ela não vê (M05–M08: requisito removido, requisito sem regra, justificativa alterada e documento com versão antiga) são justamente as que a verificação estrutural pega com certeza. Nenhum dos dois acusa a correção de pontuação N05, que o *digest* bloqueia. As duas verificações são, portanto, complementares: a estrutural é barata, determinística e exaustiva sobre vínculos; a semântica alcança o sentido, ao custo de chamadas a um modelo e de não ser determinística.

Os modelos divergem nas mudanças benignas. O GPT acusou N01 (apenas a ordem das regras no arquivo muda) e N06 (evolução completa e sincronizada). Nas justificativas, ele interpreta a ressalva "salvo fraude ou falha prioritária" do documento como uma condição que a regra de falha operacional, avaliada antes, contrariaria. Essa leitura é discutível, mas não absurda: aponta uma ambiguidade real do texto da política. O fato de N01 ser acusado, embora o par original sincronizado tenha passado, indica também sensibilidade à ordem de apresentação e variação entre chamadas. Antes desta execução, a instrução foi revisada uma vez: na primeira versão, as demais regras apareciam sem suas condições, e o GPT acusava divergências até no par sincronizado, por não ver que a regra de fraude decide antes da exceção *premium*. Os resultados reportados usam a versão revisada para os dois modelos.

6.3. Agente com LLM Real

Para observar o efeito da deriva sobre um agente com LLM, os 18 casos foram executados com cada modelo em três condições: **B1**, em que o LLM recebe os fatos do caso e todos os documentos e decide sozinho; **B1-RAG**, igual a B1, mas o LLM recebe apenas os dois documentos mais próximos da pergunta por similaridade de embeddings, com um limiar de confiança (0,30) abaixo do qual o caso vai para revisão humana sem chamar o LLM; e **P**, em que a guarda SDD e a regra determinística decidem e o LLM só redige a resposta. Cada condição foi executada com documentos sincronizados (v2) e com documentos antigos (v1) diante da política vigente (Figura 7).

Os dois modelos produzem o mesmo padrão em B1. Com documentos sincronizados, acertam 17 de 18 casos; o erro, nos dois, é C13 (horário de despacho desconhecido),

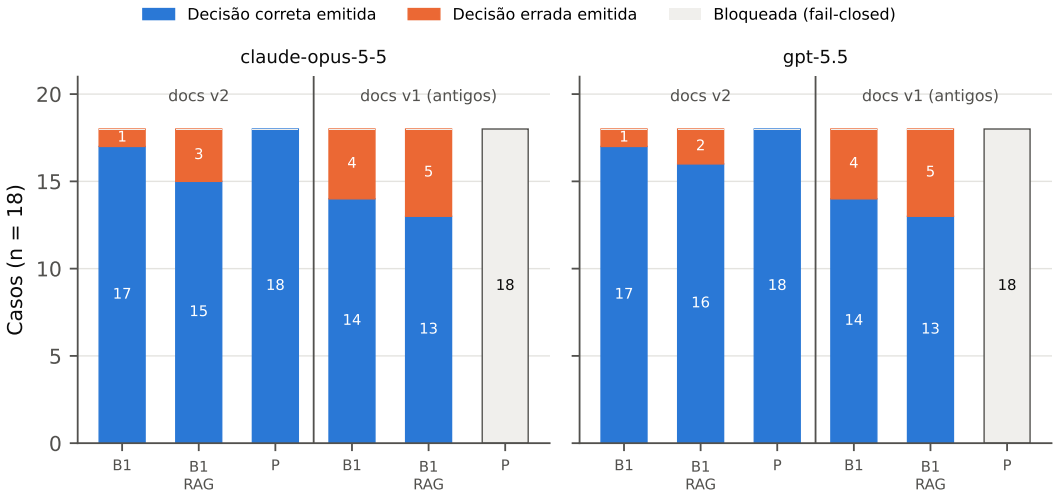


Figura 7. Decisões das condições B1 (LLM decide a partir de todos os documentos), B1-RAG (LLM decide a partir dos documentos recuperados) e P (SDD decide, LLM explica), com documentos sincronizados e desatualizados, para cada modelo.

em que escolhem revisão humana onde a especificação manda negar. Mesmo sem deriva, portanto, o LLM não reproduz exatamente as regras. Com documentos antigos, ambos erram 4 casos, os mesmos. Três deles (C05, C06 e C18) são exatamente os casos afetados pela mudança v1→v2: o LLM nega o reembolso ao cliente *premium* porque o documento antigo não traz a exceção, sem qualquer sinal de erro.

A recuperação semântica piora o quadro: B1-RAG erra 5 casos com documentos antigos nos dois modelos, e 3 (Claude) ou 2 (GPT) com documentos sincronizados. O erro novo comum aos dois é C17 (falha da transportadora com suspeita de fraude): o documento de antifraude não está entre os dois recuperados, e o LLM decide sem a regra de segurança. O limiar de confiança nunca foi acionado, pois a menor similaridade do primeiro documento foi 0,56. Esse é um modo de falha conhecido de RAG [Barnett et al. 2024], e mostra que a recuperação, sozinha, não garante que a evidência certa chegue ao modelo.

Na condição P, todas as decisões emitidas estão corretas, com os dois modelos. Com documentos sincronizados, cada LLM redigiu 16 respostas e todas passaram na conferência de decisão e de citação; nos 2 casos restantes não há documento a citar (decisão padrão) e vale a justificativa da regra. Com documentos antigos, a guarda bloqueia os 18 casos antes de qualquer chamada ao LLM.

7. Plano de Pesquisa

Questões de pesquisa. A questão principal é: *em que medida um fluxo orientado por especificações versionadas melhora a detecção de inconsistências e a rastreabilidade de decisões de agentes híbridos ao longo da evolução de políticas de negócio?* Ela se desdobra em quatro questões:

- **QP1:** a abordagem aumenta a taxa de detecção de divergências entre especificações, regras e documentos, em comparação com *baselines* sem verificação de coevolução?
- **QP2:** a abordagem reduz decisões justificadas com evidência desatualizada durante

atualizações controladas de políticas?
- **QP3:** quais custos adicionais a abordagem introduz (bloqueios, manutenção, latência e revisão humana)?
- **QP4:** em quais condições a verificação estrutural deixa passar divergências semânticas, e qual é o benefício incremental de revisão humana ou de verificação assistida por LLM?

As hipóteses são direcionais e orientam a coleta: **H1**, a verificação SDD tem maior sensibilidade do que o versionamento convencional na detecção de deriva; **H2**, ela reduz a proporção de decisões emitidas com evidência versionada incorretamente, com bloqueios contabilizados à parte; e **H3**, ela impõe custos de manutenção e de indisponibilidade mensuráveis e não desprezíveis.

Etapas. O estudo segue as diretrizes de experimentação em Engenharia de Software de [Wohlin et al. 2012] e está organizado em quatro etapas:

1. *Revisão sistemática* [Kitchenham and Charters 2007] sobre *policy-as-code*, conformidade de agentes, evolução de bases RAG, rastreabilidade em sistemas com LLM e SDD.
2. *Corpus de mudanças e operadores de mutação*, com múltiplas políticas e famílias de mudança (exceções, precedência, limiares, documentos conflitantes, inversão semântica com metadados preservados, atualização parcial e requisitos ambíguos), vários mutantes por família e rótulos atribuídos por avaliadores independentes, cegos ao validador.
3. *Integração com LLMs e condições experimentais*, sob o mesmo modelo, corpus, limite de *tokens*, temperatura e tarefas: B1 (agente RAG sem guardas de regra); B2 (agente RAG com regras determinísticas e validação de saída); B3 (B2 com versionamento convencional); P (B3 com verificação SDD, rastreabilidade e bloqueio); e P+S (P com verificação semântica assistida por LLM). O *baseline* B3 permite atribuir os ganhos à verificação SDD, e não apenas ao versionamento; P+S responde a QP4. O protótipo v0.3.0 já implementa B1, P e o verificador de P+S (Seção 6), com Claude e GPT intercambiáveis; o estudo os ampliará para vários modelos e repetições, pois as respostas de LLMs variam entre execuções.
4. *Análise*, com sensibilidade e precisão dos alertas, acurácia com bloqueios reportados à parte, cobertura, validade da evidência, rastreabilidade e custo (latência p50/p95, *tokens*, esforço de atualização e taxa de revisão humana). Intervalos de confiança serão estimados por *bootstrap* agrupado por cenário [Efron and Tibshirani 1993], e comparações pareadas de acerto binário usarão o teste de McNemar [McNemar 1947], com correção para comparações múltiplas. O tamanho amostral será definido por estudo piloto e análise de poder, e o protocolo será pré-registrado.

Cronograma. A Figura 8 apresenta o cronograma previsto para 24 meses. Para doutorado, as etapas 2 a 4 podem ser repetidas em mais domínios e complementadas por estudo de caso em ambiente real [Runeson and Höst 2009].

8. Ameaças à Validade

Em relação à *validade de construto*, *fingerprints* e *digests* verificam estrutura e integridade, não significado, e o oráculo exige revisão independente. Quanto à *validade interna*, um *baseline* simplificado favoreceria a proposta, por isso as condições serão pareadas em funcionalidade e recursos; além disso, mutantes escritos pelo mesmo autor do validador introduzem viés de construção, a ser mitigado com geração sistemática e rotulagem por

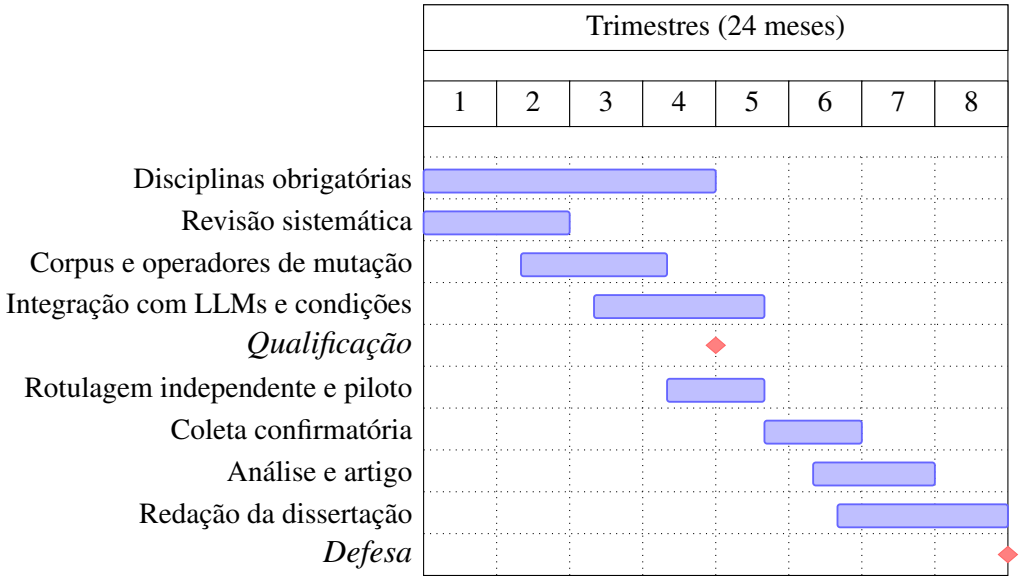


Figura 8. Cronograma previsto.

terceiros. Quanto à *validade externa*, políticas fictícias não representam sistemas regulados reais, e o estudo buscará ao menos um cenário inspirado em documentação pública de um domínio real. Quanto à *validade de conclusão*, casos correlacionados exigem unidade de análise adequada, e o uso de poucos LLMs restringe a generalização. Os resultados com LLM vêm de uma única execução de cada um dos dois modelos; o *cache* garante a reprodução dessas respostas, mas não a estabilidade do modelo em novas execuções. Além disso, a instrução do verificador semântico foi escrita conhecendo os operadores de mutação, o que pode favorecer a detecção; o estudo confirmatório usará mutantes e rótulos produzidos por terceiros. Por fim, do ponto de vista operacional, a política *fail-closed* aumenta bloqueios, cujo custo será medido e reportado.

9. Considerações Finais

Este projeto trata de um problema simples de enunciar e difícil de perceber na prática: quando uma política de negócio muda, a regra em código e o documento que a justifica podem deixar de dizer a mesma coisa, sem que o agente de IA apresente qualquer erro. O EvoPolicy-SDD propõe amarrar requisitos, regras e documentos numa especificação versionada e bloquear decisões quando esses artefatos divergem. O protótipo atual mostra, em pequena escala, que as marcas de integridade explicam a maior parte do ganho sobre o versionamento convencional (de 2 para 8 derivas detectadas em 12), que o *digest* de texto amplia a detecção ao custo de bloqueios por mudanças benignas, e que derivas semânticas com marcas recalculadas escapam a qualquer verificação estrutural. A primeira integração com LLMs reais indica que a verificação semântica fecha essa lacuna no cenário estudado, com os dois modelos avaliados, embora com taxas de alarme falso diferentes, e que, sem a guarda, um agente que decide pelos documentos reproduz a deriva em silêncio, com ou sem recuperação semântica.

Do ponto de vista científico, o trabalho pretende contribuir na interseção entre Engenharia de Software, rastreabilidade e sistemas baseados em LLMs, com um estudo controlado sobre ganhos, custos e limites da verificação de coevolução. Do ponto de vista prático, pretende oferecer um mecanismo aplicável a equipes que operam agentes sobre

políticas que mudam com frequência, sem substituir a revisão humana. Como próximos passos, estão a revisão sistemática, a ampliação do corpus de mudanças as execuções repetidas, para medir a variação entre chamadas observada na comparação entre Claude e GPT, e a medição de custo e latência da verificação semântica.

Disponibilidade dos Artefatos

O protótipo EvoPolicy-SDD v0.3.0 está disponível em repositório público (`https://github.com/L42Matheus/evopolicy-sdd`). Esse material inclui: (i) código-fonte do pacote `evopolicy` e sua suíte de 57 testes automatizados, que simulam o LLM e rodam sem acesso à rede; (ii) especificações v1 e v2, bases documentais e os 18 casos sintéticos rotulados; (iii) resultados brutos da demonstração e do estudo de mutações (`results/`), incluindo o registro auditável das decisões; (iv) os *caches* com as respostas dos LLMs e os embeddings usados neste texto (`llm_cache/`), que permitem refazer as Seções 5.2 e 5.3 sem chave de API; e (v) o *script* que gera as figuras deste texto a partir desses resultados.

Uso de Inteligência Artificial

Em conformidade com o Código de Conduta para Autores da SBC, declara-se que ferramentas de IA foram utilizadas como apoio. O *Claude* (Anthropic) foi utilizado como apoio à implementação do protótipo, à geração das figuras a partir dos resultados e à redação e organização deste texto. Separadamente, o Claude Opus 5.5 e o GPT-5.5 (OpenAI) são objetos do estudo: são os modelos avaliados no verificador semântico e no agente da Seção 5.3, sendo o conteúdo científico, a verificação das referências e as conclusões apresentadas de responsabilidade exclusiva do autor.

Referências

Aghajani, E., Nagy, C., Vega-Márquez, O. L., Linares-Vásquez, M., Moreno, L., Bavota, G., and Lanza, M. (2019). Software documentation issues unveiled. In *Proceedings of the 41st International Conference on Software Engineering (ICSE)*, pages 1199–1210. DOI: `https://doi.org/10.1109/ICSE.2019.00122`.

Barnett, S., Kurniawan, S., Thudumu, S., Brannelly, Z., and Abdelrazek, M. (2024). Seven failure points when engineering a retrieval augmented generation system. In *Proceedings of the IEEE/ACM 3rd International Conference on AI Engineering – Software Engineering for AI (CAIN 2024)*. arXiv:2401.05856.

Barr, E. T., Harman, M., McMinn, P., Shahbaz, M., and Yoo, S. (2015). The oracle problem in software testing: A survey. *IEEE Transactions on Software Engineering*, 41(5):507–525. DOI: `https://doi.org/10.1109/TSE.2014.2372785`.

Choi, J., Yoon, J., Le, L. T., Jha, S., and Pfister, T. (2026). PolicyBank: Evolving policy understanding for LLM agents. arXiv:2604.15505.

Cleland-Huang, J., Gotel, O. C. Z., Huffman Hayes, J., Mäder, P., and Zisman, A. (2014). Software traceability: Trends and future directions. In *Future of Software Engineering (FOSE 2014)*, pages 55–69. DOI: `https://doi.org/10.1145/2593882.2593891`.

Datla, G. V., Vurity, A., Dash, T., Ahmad, T., Adnan, M., and Rafi, S. (2025). Executable governance for AI: Translating policies into rules using LLMs. arXiv:2512.04408.

DeMillo, R. A., Lipton, R. J., and Sayward, F. G. (1978). Hints on test data selection: Help for the practicing programmer. *Computer*, 11(4):34–41. DOI: `https://doi.org/10.1109/C-M.1978.218136`.

Efron, B. and Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall, New York.

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., and Wang, H. (2023). Retrieval-augmented generation for large language models: A survey. arXiv:2312.10997.

GitHub (2025). Spec kit: toolkit for spec-driven development. https://github.com/github/spec-kit. Acesso em: 11 nov. 2026.

Gotel, O. C. Z. and Finkelstein, A. C. W. (1994). An analysis of the requirements traceability problem. In *Proceedings of the IEEE International Conference on Requirements Engineering (ICRE)*, pages 94–101. DOI: https://doi.org/10.1109/ICRE.1994.292398.

Hashmi, M., Governatori, G., Lam, H.-P., and Wynn, M. T. (2018). Are we done with business process compliance: State of the art and challenges ahead. *Knowledge and Information Systems*, 57(1):79–133. DOI: https://doi.org/10.1007/s10115-017-1142-1.

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., and Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12). DOI: https://doi.org/10.1145/3571730.

Jia, Y. and Harman, M. (2011). An analysis and survey of the development of mutation testing. *IEEE Transactions on Software Engineering*, 37(5):649–678. DOI: https://doi.org/10.1109/TSE.2010.62.

Kitchenham, B. and Charters, S. (2007). Guidelines for performing systematic literature reviews in software engineering. Technical Report EBSE-2007-01, Keele University and Durham University.

Lee, H., An, G., and Yoo, S. (2025). METAMON: Finding inconsistencies between program documentation and behavior using metamorphic LLM queries. arXiv:2502.02794.

Lehman, M. M. (1980). Programs, life cycles, and laws of software evolution. *Proceedings of the IEEE*, 68(9):1060–1076. DOI: https://doi.org/10.1109/PROC.1980.11805.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., and Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, pages 9459–9474. Disponível em: https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html.

Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., and Liang, P. (2024). Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173. DOI: https://doi.org/10.1162/tacl_a_00638.

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153–157. DOI: https://doi.org/10.1007/BF02295996.

Meyer, B. (1992). Applying "design by contract". *Computer*, 25(10):40–51. DOI: https://doi.org/10.1109/2.161279.

National Institute of Standards and Technology (2015). Secure hash standard (SHS). Federal Information Processing Standards Publication FIPS PUB 180-4, NIST, Gaithersburg, MD. DOI: https://doi.org/10.6028/NIST.FIPS.180-4.

National Institute of Standards and Technology (2023). Artificial intelligence risk management framework (AI RMF 1.0). Technical Report NIST AI 100-1, NIST, Gaithersburg, MD. DOI: https://doi.org/10.6028/NIST.AI.100-1.

Nygard, M. (2011). Documenting architecture decisions. https://cognitect.com/blog/2011/11/15/documenting-architecture-decisions. Acesso em: 11 nov. 2026.

Open Policy Agent (s.d.). Open policy agent: Policy-based control for cloud native environments. https://www.openpolicyagent.org/docs. Acesso em: 11 nov. 2026.

Ouyang, J., Pan, T., Cheng, M., Yan, R., Luo, Y., Lin, J., and Liu, Q. (2025). HoH: A dynamic benchmark for evaluating the impact of outdated information on retrieval-augmented generation. arXiv:2503.04800.

Papadakis, M., Kintis, M., Zhang, J., Jia, Y., Le Traon, Y., and Harman, M. (2019). Mutation testing advances: An analysis and survey. In *Advances in Computers*, volume 112, pages 275–378. Elsevier. DOI: https://doi.org/10.1016/bs.adcom.2018.03.015.

Raji, I. D., Smart, A., White, R. N., Mitchell, M., Gebru, T., Hutchinson, B., Smith-Loud, J., Theron, D., and Barnes, P. (2020). Closing the AI accountability gap: Defining an end-to-end framework for internal algorithmic auditing. In *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency (FAT* '20)*, pages 33–44. DOI: https://doi.org/10.1145/3351095.3372873.

Ramesh, B. and Jarke, M. (2001). Toward reference models for requirements traceability. *IEEE Transactions on Software Engineering*, 27(1):58–93. DOI: https://doi.org/10.1109/32.895989.

Rebedea, T., Dinu, R., Sreedhar, M. N., Parisien, C., and Cohen, J. (2023). NeMo guardrails: A toolkit for controllable and safe LLM applications with programmable rails. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 431–445. Disponível em: https://aclanthology.org/2023.emnlp-demo.40.

Rinderle, S., Reichert, M., and Dadam, P. (2004). Correctness criteria for dynamic changes in workflow systems – a survey. *Data & Knowledge Engineering*, 50(1):9–34. DOI: https://doi.org/10.1016/j.datak.2004.01.002.

Runeson, P. and Höst, M. (2009). Guidelines for conducting and reporting case study research in software engineering. *Empirical Software Engineering*, 14(2):131–164. DOI: https://doi.org/10.1007/s10664-008-9102-8.

Schmidt, D. C. (2006). Model-driven engineering. *Computer*, 39(2):25–31. DOI: https://doi.org/10.1109/MC.2006.58.

Tan, L., Yuan, D., Krishna, G., and Zhou, Y. (2007). /* iComment: Bugs or bad comments? */. In *Proceedings of the 21st ACM SIGOPS Symposium on Operating Sys-*

tems Principles (SOSP), pages 145–158. DOI: https://doi.org/10.1145/1294261.1294276.

União Europeia (2024). Regulamento (UE) 2024/1689 do parlamento europeu e do conselho, de 13 de junho de 2024, que cria regras harmonizadas em matéria de inteligência artificial (regulamento da inteligência artificial). Jornal Oficial da União Europeia, Série L, 12 jul. 2024. Disponível em: https://eur-lex.europa.eu/eli/reg/2024/1689/oj.

Wang, L., Ma, C., Feng, X., Zhang, Z., Yang, H., Zhang, J., Chen, Z., Tang, J., Chen, X., Lin, Y., Zhao, W. X., Wei, Z., and Wen, J. (2024). A survey on large language model based autonomous agents. *Frontiers of Computer Science*, 18(6). DOI: https://doi.org/10.1007/s11704-024-40231-1.

Wen, F., Nagy, C., Bavota, G., and Lanza, M. (2019). A large-scale empirical study on code-comment inconsistencies. In *Proceedings of the 27th IEEE/ACM International Conference on Program Comprehension (ICPC)*, pages 53–64. Disponível em: https://www.inf.usi.ch/faculty/lanza/PUBS/P/Wen2019a.pdf.

Wohlin, C., Runeson, P., Höst, M., Ohlsson, M. C., Regnell, B., and Wesslén, A. (2012). *Experimentation in Software Engineering*. Springer, Berlin, Heidelberg. DOI: https://doi.org/10.1007/978-3-642-29044-2.

Xu, X., Wahab, Z., Holmes, R., and Lemieux, C. (2025). DocPrism: Multi-lingual detection of incorrectness inconsistencies between code and documentation. arXiv:2511.00215.

Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., and Cao, Y. (2023). ReAct: Synergizing reasoning and acting in language models. In *International Conference on Learning Representations (ICLR 2023)*. arXiv:2210.03629.

Zaidman, A., Van Rompaey, B., van Deursen, A., and Demeyer, S. (2011). Studying the co-evolution of production and test code in open source and industrial developer test processes through repository mining. *Empirical Software Engineering*, 16(3):325–364. DOI: https://doi.org/10.1007/s10664-010-9143-7.

Zwerdling, N., Boaz, D., Rabinovich, E., Uziel, G., and Anaby-Tavor, A. (2025). Towards enforcing company policy adherence in agentic workflows. arXiv:2507.16459.